

## 2022년도 DDFE 동계학부연구생 프로그램 연구보고서

연구명	국문	도심 유동장 예측
	영문	Predict flow field in an urban area

## 1. 연구의 필요성 [1 page]

### 1) 연구의 배경

- 

## 2. 연구의 목표 및 내용 [3 page]

### 1) 연구의 최종 목표

- 바람의 흐름을 저해하는 고층 건물이 존재하지 않는 자연 개활지나 저층 건물들로 이루어진 교외 지역의 경우 공기 유동의 변화 요인이 많지 않기 때문에 바람 유동의 특이점은 발생하지 않는다. 그러나 고층 건물의 밀도가 높은 도심에서는 바람의 흐름이 건물에 막혀 왜곡되며 유동 방향과 속도의 큰 변화를 수반하는 복잡한 흐름을 갖기 때문에 유동 경향상의 예측이 어려워진다. 일반적으로 지표면 부근에서는 바람의 흐름이 지형이나 수목, 건물 등에 의해 발생하는 마찰력의 영향을 받기 때문에 상공에 비해 속도가 떨어지게 된다.
- 건축물에 의해 변화되는 도시 내부의 바람 유동은 보다 복잡한 경향을 보이며, 특히 고층 건물 주변에서는 특징적인 유형의 바람 흐름이 형성된다. 건물에 의해 흐름이 막힌 바람은 장애물을 회피하기 위한 공기 흐름에 의해 윗면과 옆면으로 유로가 형성되는데, 이러한 과정에서 바람의 속도가 증가하며 압력이 감소하게 된다. 이러한 건물 주위 바람의 특징적인 양상으로서 건물의 측면과 상면을 타고 넘는 바람을 박리류(Separated Flow)라 하고, 건물과의 마찰 및 건물 주변에서의 압력 변화에 의해 맴도는 바람을 와류(Vortex)라 한다. 또한 다수의 건물이 공기 유동에 복합적으로 영향을 미치는 경우 바람들이 서로 부딪치거나 합류하여 역류(Backward Flow)나 가로풍(Pathway Wind), 곡문풍(Valley Wind)이 발생하게 된다. 이러한 바람의 흐름은 개념적으로는 쉽게 이해되지만 실제 도시에서는 매우 다양한 형상의 건축물들이 조합되어 있어 공기의 순환을 예측하는 것은 쉽지 않다.
- 최근 도시 지역의 고밀도화 및 고층화에 의한 환경 문제로 인해 도심 지역의 공기 유동에 대한 관심이 높아지고 있으며, 이에 따라 건축물의 적절한 형상 및 배치 설계가 요구되고 있다. 본 연구에서는 인공지능을 통하여 건물 주위의 바람에 의한 공기 유동 경향을 분석한 후 학습 결과를 시각화함으로써 제안된 연구 방법의 유용성을 검토하였다. 이러한 연구의 결과로서 도심 건물에 의해 발생하는 박리풍과 와류의 형성 영역을 관찰할 수 있으며 제안된 연구 방법이 건축물 설계 및 도시 계획에 유용하게 활용될 수 있다.

## 2) 연구의 내용

### ● 도심 시간 평균 유동장 분석

- ◆ 초기 u-velocity가 5일 때의 유동장과 실측한 유동장을 비교·분석하였다. 바람이 건물의 정면에 부딪혔을 때, 상하좌우로 나뉘게 되고 건물 사이를 지나며 속력이 강해지는 흐름을 보였다. 건물의 뒷편에서는 작은 소용돌이를 치면서 좌우로 흘러가는 양태를 보였다. 베르누이 정리와 벤투리 효과를 통해 이러한 유동을 보이는 이론적인 배경을 학습하고 도심을 지나는 바람이 건물에 부딪쳐 갈라져 불 때 좁은 지역에서는 강한 바람이 만들어질 수 있고, 특히 건물과 건물 사이에서는 아주 강한 바람이 불게 되는 것을 확인하였다.

### ● 데이터 전처리 및 데이터 시각화 (Data preprocessing and Data visualization)

- ◆ 이 과정은 데이터가 기존에 가지고 있는 2차원의 행렬의 형태의 Dataset을 현실 공간에 맞게 3차원 공간으로 변환하는 작업을 거친다. 총 1,080,770개의 좌표계에 대한 벡터값을 (46, 185, 127) 의 shape을 가진 3차원 행렬로 변환한다. 이 때 46 높이의 y축을 기준으로 (x,z) 평면의 데이터를 적층하는 구조로 데이터 전처리를 하였으며, Fortran 배열방식으로 적층하였다. 해당 방법으로 적층한 후 수치를 colormap을 통해 시각화하고 x,y 평면을 기준으로 자른 그림은 다음과 같다.




그림 1. x = 85 지점에서의 u의 Input data




그림 2. x = 85 지점에서의 u의 Ground Truth data

### ● Least Square matrix 를 통한 유동장 예측

- ◆ 주어진 dataset에서의 Input data는 초기 조건으로 u-velocity가 일정한 velocity를 지니고, w-velocity와 v-velocity는 모두 0으로 고정되어있다. 이 유동이 건물을 통과한 이후의 데이터들이 Label data가 되며 상기한 바와 같이 베르누이 정리와 벤츄리 효과에 의해 각 좌표계에서 데이터 값들이 변화한다. input data를 A matrix, Label data를 b matrix로 정의하면 Least Square Method를 통해 두 행렬 A,b 간의 관계를 설명할 수 있는 근사해 x를 구할 수 있게된다.  $Ax = b$  에서의 도출된 근사해 x를 통해 새로운 초기조건을 가진 유동장이 Input data로 들어오

게 되더라도 유동장을 굉장히 정확하게 예측할 수 있다. 결정계수는 0.9879 정도에 1에 근사한 값이 나왔으며, Input data와 Label data 간의 상관관계 정도가 매우 크다는 것을 증명한다. 다만, 해당 Method의 경우에는 solution의 data size가 굉장히 커지게 되고 이에 따라 계산비용이 굉장히 많이 든다. 3차원의 경우에 이를 적용하게 되면 (1,080,770, 1,080,770) 크기의 matrix가 생성되고, 연산이 원활하게 이루어지지 않았다. 따라서 2차원형태의 그림(1)의 유동장을 예측하는 코드를 구성했고, 초기 속도가 5일 때의 prediction을 시각화한 결과는 다음과 같다.

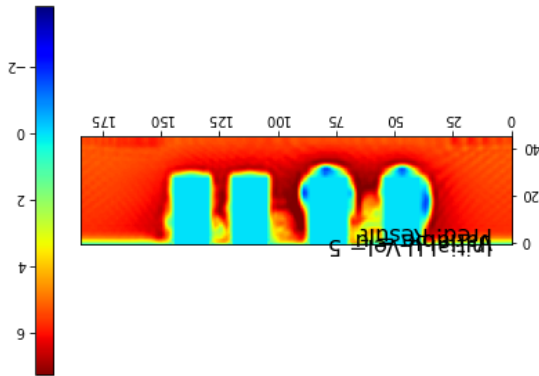


그림 4.  $x = 85$  지점에서의  $u$ 의 prediction (least square method)




그림 6.  $x = 85$  지점에서의  $u$ 의 Ground Truth data

u 평균절대오차 : 0.09137425766932304  
v 평균절대오차 : 0.09925954752972814  
w 평균절대오차 : 1.7956511830494497  
p 평균절대오차 : 0.12660077941308467

그림 8. least square method의 MAE


결정계수: 0.9878943806517604

그림 9. least square method의 결정계수

## ● CNN(Convolution Neural Network)를 통한 유동장 예측

- 계산비용에서 Least square method의 한계점을 느껴, 계산비용과 Data size 를 줄이고자 CNN을 통해 Input data와 Label data 간의 상관관계를 설명할 수 있는 모델을 만들었다.

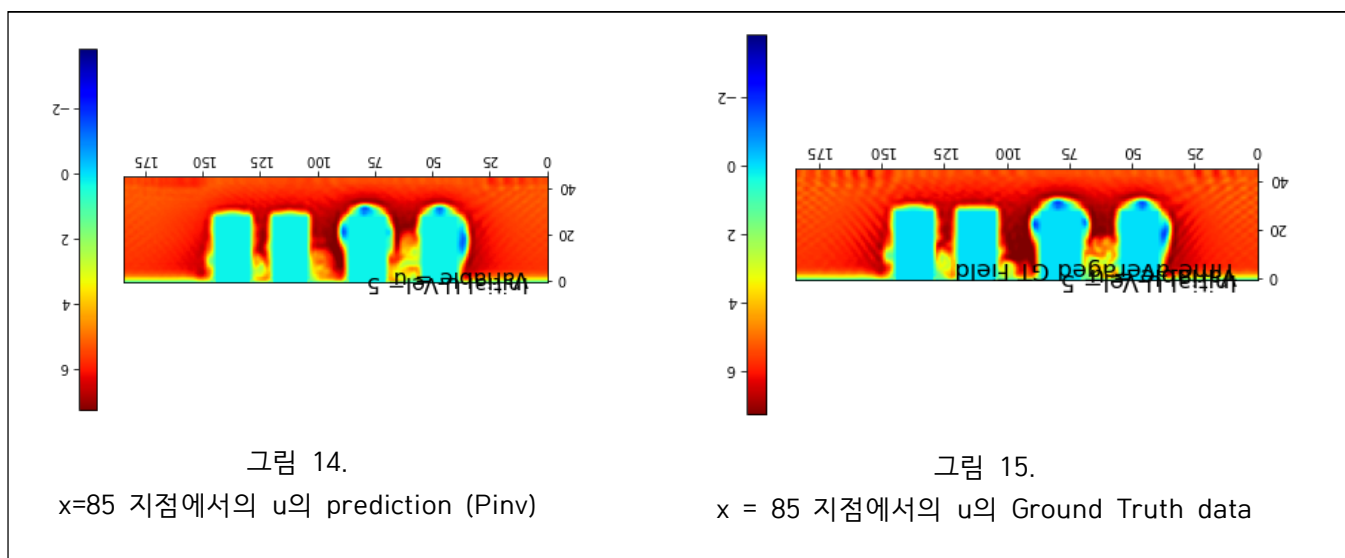
CNN은 Least Square method 나 후술할 Pseudo inverse matrix와는 다르게 단순한 행렬 연산이 아니며, 기본적으로 딥러닝 아키텍처이다. 이미지 분석에 많이 쓰이는 CNN은 행렬의 영역들을 여러장의 kernel로 훑듯이 탐색하고 feature map을 생성한다. 여러장의 feature 맵을 통해 나온 특징점들을 통해 solution을 도출한다. 이 과정에서 전체 행렬을 하나하나 계산하는 형식이 아니므로 계산비용이 매우 저렴해진다. 초기 속도가 4.25 일 때, CNN을 통해 구한 prediction을 시각화한 결과는 다음과 같다.



prediction 결과가 오차가 매우 큰 것을 관측할 수 있다. 이는 training data의 부족으로 인해 모델이 underfitting 되었기 때문인 것으로 보인다. 이를 해결하기 위해서는 데이터 증강(Data argumentation) 을 통해 데이터 셋을 늘리는 방안을 고려해볼 수 있다.

#### ● Pseudo inverse matrix를 통한 유동장 예측

- 기존의 방식에서의 Input data size는 (1,080,770, 1) 이었다. 초기 조건의 경우 모든 영역에서 속도가 일정하기 때문에 Input data를 모두 사용하지 않아도 된다. 따라서 data file 하나당 하나의 scalar 값, 즉 초기속도만 Input data로 넣어주면 data size를 (1,1) 의 형태로 만들어 줄 수가 있다.  $Ax = b$  의 솔루션  $x$ 를 구하는 과정에서 초기속도 행렬, 즉  $A$  matrix가 정사각행렬이 아닌 관계로 유사 역행렬(Pseudo inverse matrix)를 통해  $Ax = b$ 를 만족하는  $x$  matrix의 근사해를 구할 수 있다. 결정계수는 0.9338 정도에 1에 근사한 값이 나왔으며, Input data와 Label data 간의 상관관계 정도가 매우 크다는 것을 증명한다. 초기속도가 5일 때, Pseudo inverse matrix를 통해 구한 prediction을 시각화하면 다음과 같다.



u 평균절대오차 : 0.7658755397706432  
v 평균절대오차 : 0.7105112323833667  
w 평균절대오차 : 0.37422511697875493  
p 평균절대오차 : 0.44751450099948653

그림 16. Pseudo inverse matrix의 MAE

결정계수 : 0.9338478179595384

그림 17. Pseudo inverse matrix의 결정계수

### 3. 연구에서의 각 학생들의 역할 [0.5 page]

#### -방성진(팀장)

- CNN, Pseudo inverse matrix 코드 구현, ML mathematics
- Data preprocessing, Data visualization

#### -임서윤

- 도심 유동장 논문 분석
- CNN 코드 설계, BaseLine code 분석

### 4. 연구의 활용방안 및 기대효과 [0.5 page]

#### 1) 연구의 활용방안

- 도심에서 빌딩 건축 전 설계 단계에서 빌딩 건축 이후 생성될 유동장을 예측하여, 피해를 줄일 수 있다.
- 특정 대기오염물질의 이동경로를 예측하여 도심으로의 유해물질 확산을 방지할 수 있다.

#### 2) 연구의 기대효과

- 유동장을 예측하려면, 상기한 바와 같이 유체역학적인 분석이 필요하다. 굉장히 정확하긴 하겠지만, 예측하는 과정에서 수학적인 수식들에 의해 계산비용이 수백배 가까이 커질 수 밖에 없다. 그러나 데이터 기반으로 학습된 해당 모델을 통해 계산 비용을 상당 부분 개선할 수 있다.

## - 참고문헌(Reference)

- [1] A venturi-shaped roof for wind-induced natural ventilation of buildings: Wind tunnel and CFD evaluation of different design configurations - T. van Hooff, B. Blocken, L. Aanen, B. Bronsema
- [2] Modeling of coupled urban wind flow and indoor air flow on a high-density near-wall mesh: Sensitivity analyses and case study for single-sided ventilation - Z.T. Ai, C.M. Mak
- [3] Exposure Assessment of Traffic-Related Air Pollution Based on CFD and BP Neural Network and Artificial Intelligence Prediction of Optimal Route in an Urban Area - Lulu Ren, Farun An, Meng Su, Jiyong Liu
- [4] 처음 시작하는 딥러닝:수학 이론과 알고리즘부터 CNN RNN 구현까지 한 권으로 해결하기 - 세스 와이드먼
- [5] Hands-On Machine Learning with Scikit-Learn Keras and Tensorflow - Géron, Aurélien